Extrakce obsahů knih

Adam Malysák | Patrik Nehéz | Ondřej Lukášek

Popis úlohy

Cíl

Cílem projektu je adaptovat a otestovat VLLM modely pro extrakci obsahů knih do strukturovaného formátu, a to včetně zachování hierarchické struktury textu i určení geometrické pozice prvků na stránce.

Extrahované údaje

- Název kapitoly,
- číslo kapitoly,
- číslo strany,
- popis nebo podnadpis kapitoly,
- následující podkapitoly.

Dataset

- 1426 naskenovaných stran.
- Ke každé anotace a OCR.
- OCR + anotace → JSON.
- Vytvoření struktury kapitol a podkapitol.

Testované modely

- GPT-4o
- GPT-5.4
- Qwen3-VL-2B*
- Qwen3-VL-4B*
- Qwen3-VL-8B*

*fine-tuned

Oprava datasetu

+

json — Ground Truth

```
[
    {
        "name": "SOKOLÍ HNÍZDA",
        "chapter_number": null,
        "page_number": "7",
        "description": null,
        "name_bbox": [
            [93,662],
            [462,716]],
        "chapter_number_bbox": null,
        "page_number_bbox": [
            [1188,665],
            [1228,709]],
        "description_bbox": null,
        "subchapters": []
    },
    ...
]
```

→

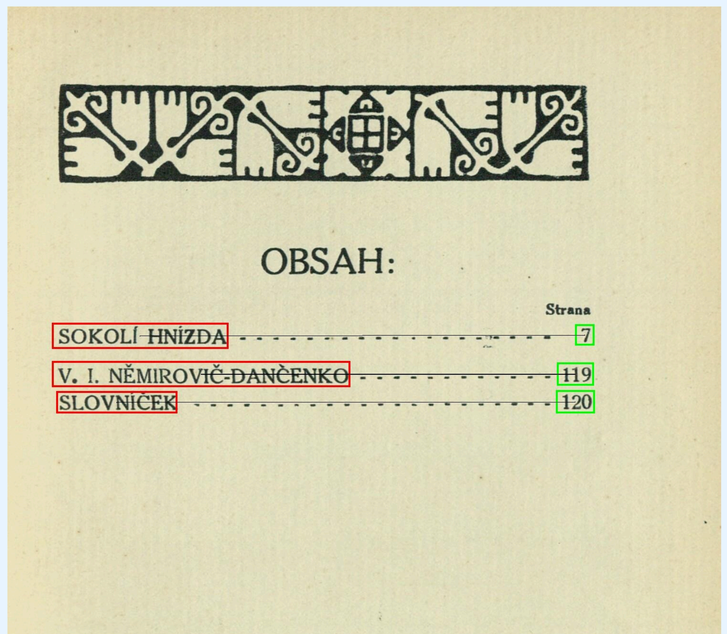

Výsledky

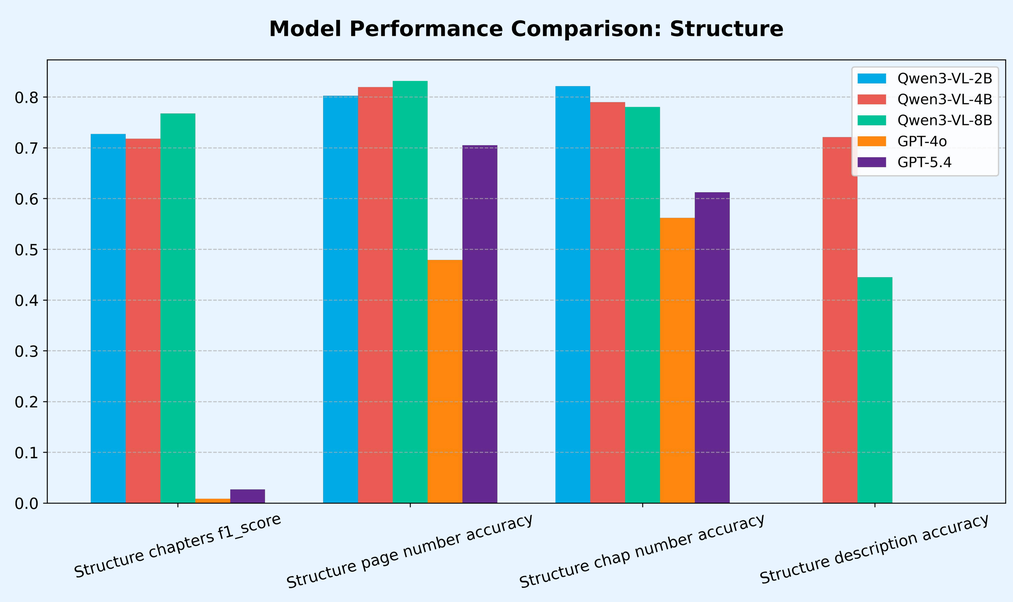

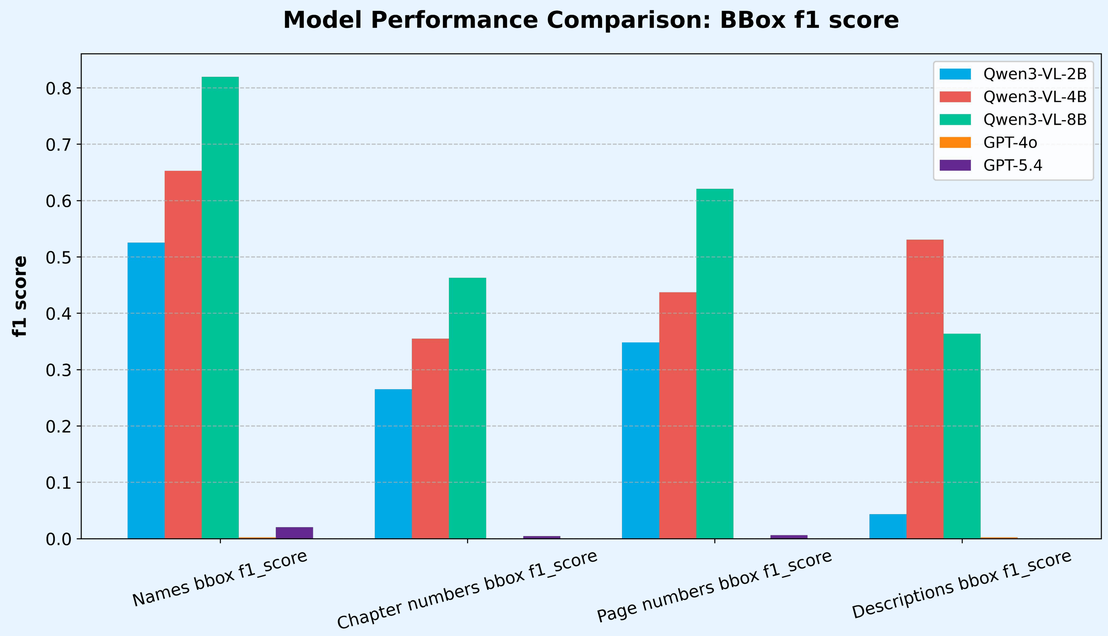

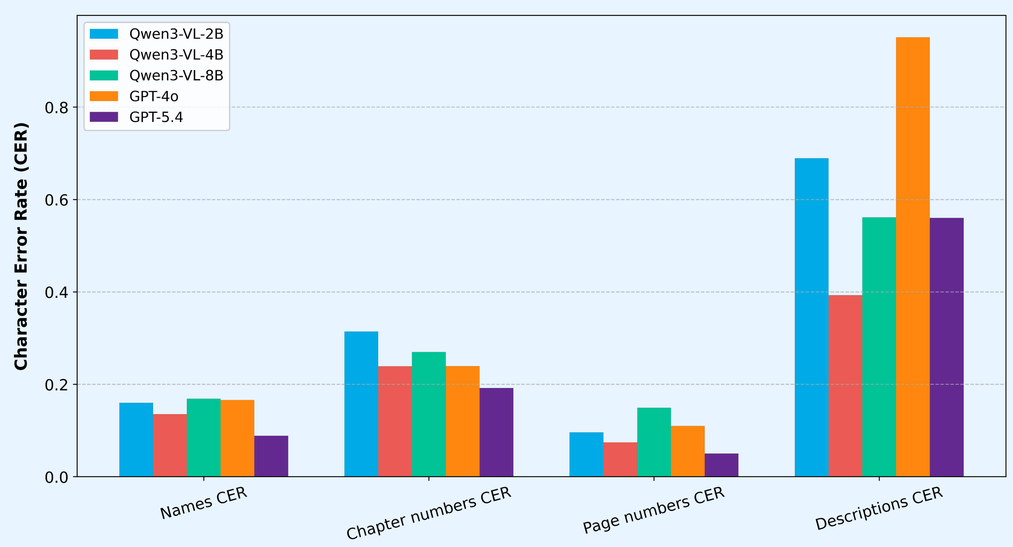

Popis Výsledků

- **Komerční modely (GPT-4o, GPT-5.4)** dosahují nízké chybovosti textu s **CER pod 0.2** u většiny kategorií, ale v lokalizaci bounding boxů a dodržení hierarchické stromové struktury **zcela selhávají**.
- Adaptace modelů řady **Qwen3-VL** pomocí finetuningu znatelně zvýšila strukturální přesnost, přičemž metrika **Structure F1** u všech tří trénovaných variant stabilně **přesahuje hodnotu 0.7**.
- U úspěšně spárovaných kapitol a podkapitol se přesnost určení doplňkových atributů, jako čísla stran a kapitol, pohybuje **kolem 0.8**.
- Z hlediska geometrie lokalizace a správné rekonstrukce hierarchického JSON stromu vykazuje **nejlepší výsledky model Qwen3-VL-8B**. Menší varianty (**4B a 2B**) vykazují mírně **nižší chybovost CER** čistě při zpracování textové složky.